

K.J. Bergen, P. A. Johnson, M. V. de Hoop, G. C. Beroz. 2019. Machine learning for data-driven discovery in solid Earth geoscience. *Science* **363**, eaau0323. doi:10.1126/science.aau0323

张美玲, 高东辉, 张永刚, 杜秋男 译. 2020. 固体地球科学中基于数据驱动发现的机器学习. 世界地震译丛. **51**(1): 1-21. doi: 10.16738/j.cnki.issn.1003-3238.202001001

综述概要

固体地球科学中基于数据驱动发现的机器学习

K. J. Bergen P. A. Johnson M. V. de Hoop G. C. Beroza

背景: 固体地球、海洋和大气共同形成了复杂的相互作用的地球系统。适宜于了解地球系统状态的过程, 其范围从原子到行星的空间尺度和从毫秒到数十亿年的时间尺度。物理、化学和生物学过程相互作用并对这个复杂的地球系统有很大的影响。人类也与之互相影响, 随着地球的有限性变得越来越明显, 对可用能源、矿产资源和淡水的限制也越来越严重地影响着人类的活动, 这些方式对自然世界及文明的未来产生了越来越大的影响。地球受到各种地质灾害的影响, 人们对这些灾害了解甚少, 但随着城市化程度的提高, 特别是在易发生灾害的地区, 灾害对地球的影响越来越大。我们有一个基本的需要, 即提高对地球系统如何工作的最好的预测理解, 这种理解必须以现在和遥远的过去为基础。这一理解将通过对日益庞大的地质数据集的分析和通过计算密集的模拟来实现, 这些模拟通常通过反演联系在一起。地球科学家们面临的首要挑战之一是如何从数据和模拟以及两者之间的相互作用中提取尽可能多的有用信息和如何获得新见解。我们认为, 快速开展的机器学习(Machine

Learning, 缩写为 ML)领域的技术将在这一挑战中发挥关键作用。


进展: 大内存的超速计算机、机器学习算法的快速进步和大型数据集的可用性这三方面汇集在一起将地球科学置于取得重大进展的起点。我们预计这一进展将来自于机器学习在三类研究工作中的应用: (i) 自动执行一项复杂的预测任务, 其不容易用一组显式命令来描述; (ii) 建模和反演, 以创建近似数值模拟或捕捉关系的表示形式; (iii) 发现并揭示新的通常意想不到的模式、结构或关系。自动化完成的例子包括: 利用遥感数据进行地质填图、描述破裂系的拓扑结构对地下运移建模, 以及将火山灰颗粒分类以推断火山喷发机制。建模的例子包括用于复杂流变性的黏弹性响应的逼近, 直接由层析成像数据确定波速模型, 以及对各种地震事件进行分类。发现的示例包括利用声发射观测预测实验室滑移事件, 用相似性搜索法检测弱地震信号, 以及利用地下水示踪观测确定地下储层的连通性。

展望: 机器学习在固体地球科学中的应用正在迅速扩大, 但仍处于起步阶段, 取得的进


展也不平衡。使用长期存在的数据源的现有数据集，仍有许多工作要做。在许多情况下这些数据源都是未经开发的。较新的非常规数据源，如光探测与测距(激光雷达)、光纤传感和众包测量，可能需要通过它们所提供的信息量和特征来采取新的方法。

实际步骤可以加速和扩大机器学习在地球科学中的应用。更广泛地采用开放科学原则，如开放源代码、开放数据和开放式访问，利用机器学习和人工智能的快速发展，将更好地确定固体地球学界的位置。由于能够进行严格的性能对比，基准数据集和挑战性问题已在推动人工智能研究进步方面起了重要作用，并一定能在地

球科学中起到类似的作用。对高质量数据集的测试产生了更好的模型，而基准数据集使得这些数据广泛地应用于研究领域。它们还有助于从相关学科补充专门知识。地球科学家与机器学习研究人员之间的密切合作将有助于在机器学习地球科学应用方面取得快速进展。从地球科学数据中提取最大值则需要新的方法将数据驱动法、物理建模和能够将有限的、弱的或有偏差的标签学习的算法结合起来。以这些学科交叉为目标的资助项目，以及在地球科学中更重视数据科学和开展更多机器学习的培训，将有助于使这一努力取得成果。



数字地质。美国本土地质数字表示(原图为彩色图——译注) [比例尺 1: 2 500 000 的美国本土地质图; 由 P. G. Schruben, R. E. Arndt, W. J. Bawiec 绘制的 1974 年 P. B. King 和 H. M. Beikman 图形的数字表示]



固体地球科学中基于数据驱动发现的机器学习

K. J. Bergen P. A. Johnson M. V. de Hoop G. C. Beroza

摘要 通过固体地球科学各个领域了解地球运转状态是一项日益重要的任务。了解地球运行状态所需的复杂的环境、相互作用和多尺度的过程使它具有挑战性,同时,几乎所有地球的地下都难以直接观测,这也是具有挑战性的原因。数据可用性的大幅增加和计算机模拟越来越逼真的特点给加快进展带来了希望,但是,基于这些功能的加深了解本身就具有挑战性。机器学习将在这一努力中发挥关键作用。我们综述该领域的现状,并就如何扩大和加快进展提出了建议。

0 引言

固体地球、海洋和大气共同形成了复杂的相互作用的地球系统。适宜于了解其运行状态的过程,其范围从原子到行星的空间尺度和从毫秒到数十亿年的时间尺度。物理、化学和生物学过程相互作用并对这个复杂的地球系统有很大的影响。人类也与之相互影响,随着地球的有限性变得越来越明显,对可用能源、矿产资源和淡水的限制也越来越严重地影响着人类的活动,这些方式对自然界及文明的未来产生了越来越大的影响。地球受到各种地质灾害的影响,人们对这些灾害了解甚少,但随着城市化程度的提高,特别是在易发生灾害的地区,灾害对地球的影响越来越大。我们有一个基本的需要,即提高对地球系统如何工作的最好的预测理解,这种理解必须以现在和遥远的过去为基础。

在这篇综述中,我们将重点放在固体地球上。了解固体地球的材料特性、化学、矿物物理学和动力学是一门极具吸引力的学

科,也是人类在 21 世纪满足所面临的能源、水和抵抗自然灾害的要求所必不可少的。了解固体地球有一个严峻的事实挑战,即几乎地球的所有内部都是不能直接观测的,而且将来依旧如此。关于内部特性和过程的知识是基于在地表或近地表进行的测量,是离散的,并且受到自然障碍物的限制,使得知识的各方面不受直接测量的约束。

由于以上原因,固体地球科学分为数据驱动和模型驱动两个领域,逆问题经常连接这两个领域。意料之外的发现将是越来越多的来自对大型数据集的分析、逆理论的新发展以及通过计算密集模拟实现的过程。在过去的 10 年里,通过大型传统传感器的部署和通过新的数据源和传感模式,极大地增加了地球科学家们可用的数据量。地球运行过程的计算机模拟在规模和复杂程度上迅速增加,使得它们变得越来越逼真,并越来越适合预测地球的运行状态。地球科学家们面临的首要挑战之一是如何从数据和模拟以及两者之间的相互作用中提取尽可能多的有用信息和如何获得新见解。我们认为,机器学习将在这一工作中发挥关键作用。




图1 科学家如何分析数据：用于科学分析的常规镜头和机器学习镜头(原图为彩色图——译注)。机器学习类似于通过新的镜头观察数据。领域专家采用的传统方法(如傅里叶分析)是预先选定的，用来检验假设，或者只是简单地以不同的方式显示数据。机器学习探索更大的函数空间，这个空间可以将数据连接到某个目标或标签上。在这样做的过程中，它提供了在高维数空间中发现变量之间关系的手段。然而，有些机器学习方法在如何找到函数和映射方面是透明的，而其他方面则是不透明的。因此，匹配合适的机器学习方法来解决问题是非常重要的

基于驱动的机器学习突破点在于最初出现在譬如计算机视觉和自然语言处理等传统领域，但其他领域的科学家快速地更广泛采用和推广了这些技术(1~4)。最近，地球科学家们对机器学习的兴趣最初集中在大型数据集的自动化分析上，但后来通过数据驱动的和模型驱动的洞察扩展到使用机器学习来达到对耦合过程更深入的理解。在这篇综述中，我们介绍了地球科学面临的挑战，提出了地球科学研究的新趋势，并提出了有助于加速进展的建议。

机器学习为从数据中提取知识和给出论断提供了一套工具(5)。它也可以被认为是

人工智能的手段(6)，人工智能涉及到能够执行具有人类智能特征任务的机器(7, 8)。机器学习的算法是为了学习经验和识别数据中的复杂模式和关系而设计的。机器学习方法对数据的分析方法与传统的分析方法不同(图1)，是一种稳健、快速且允许探索大型函数空间的方法(图2)。

机器学习算法的两个主要类别是监督学习和无监督学习。在监督学习中，机器学习算法“学习”识别模式或使用已知的例子进行一般预测。有监督的学习算法创建图像，或者模型 f ，使用标注训练数据[输入和相应标签($x^{(i)}$, $y^{(i)}$)都已知，并可供算法使用




图2 领域专家和机器学习使用的函数空间(原图为彩色图——译注)。科学家使用的用户定义函数的函数空间,与机器学习所使用的函数空间相比,包含在全部可能的函数空间中。随着计算成本和运行时间的减少,以及内存、网络深度和可用数据的增加,机器学习所使用的函数空间正在迅速扩展

的数据] 将数据(或特征)向量 $\mathbf{x}$ 与相应的标号或目标向量 $\mathbf{y}$ 相关联: $\mathbf{y} = f(\mathbf{x})$ 对模型进行优化。例如,监督机器学习分类器可以在医学图像中使用一组医师注释示例来学习检测癌症(9)。经过良好训练的模型应该能够推广,并且对以前未见的输入做出准确的预测(例如给新病人的医学图像贴上标签)。

无监督学习方法在不依赖标签特性的情况下学习数据集中的模式或结构。在众所周知的例子中,谷歌 X 实验室的研究人员开发了一种特征检测算法,即在没有提示或事先关于猫的信息的情况下,对在 YouTube 数百万张图像上暴露过的猫进行学习识别(10)。在数据集中,无监督学习常用于探索数据分析或可视化,其中没有或者几乎没有可用的标签,包括降维和聚类。

用于监督学习和无监督学习的许多不同算法各自都有相对优势和弱点。算法的选择

取决于许多因素,包括:(i)标注数据的可用性;(ii)数据向量的维数;(iii)数据集的大小;(iv)连续值与离散值预测指标;(v)期望模型的可解释性。模型可解释性的水平在地球科学应用中是特别重要的。虽然在高精度的图像识别系统中,可解释性可能不是必需的,但当目标是获得对系统的物理洞察力时,这是至关重要的。

1 固体地球科学中的机器学习

几十年来,科学家们一直在应用机器学习技术来解决固体地球科学中的问题(11~13)。尽管早期的概念验证研究表明是有帮助的,但学界在更广泛地采用机器学习方面却进展缓慢。这种情况正在迅速改变。最近机器学习中的性能突破,包括深度学习、提供强大功能和易于使用的机器学习工具箱等的进步,已使地球科学家对机器学习重新产生了兴趣。在固体地球科学中,研究人员已经利用机器学习来处理各种不同的任务,我们将这些任务划分为三种相互关联的自动化模式:建模和反演问题以及发现(图3)。

自动化是使用机器学习执行一个不易于通过一组显式命令来描述的复杂任务。在自动化任务中,机器学习主要被选择为用于进行高精度预测(或标注数据)的工具,特别是在人难以执行或解释时。在地球科学之外用于自动化的机器学习示例,包括图像识别(14)或电影推荐(15)系统。机器学习可以通过在较大的可能性集合中自动地识别更好的解决方案来改进专家设计的算法。自动化利用了机器学习算法的优势,能够从大型或高维数据集中处理和提取模式来复制或超过人类的表现。在固体地球科学中,机器学习被用于自动化大规模数据分析管道中的步骤,如地震监测(16)或地震预警(17~19),并执行专门的、重新调整的任务,否则就需要耗费专家分析人员的时间,例如对火山灰颗粒




图3 机器学习的通用模型(原图为彩色图——译注)。上面一行展示了用自动化方法通过应用随机的机器学习,用遥感数据映射岩性学的例子。该方法用稀疏的地面真实数据就很有效,并对预测岩性的不确定性给出了稳健的估计(35)。第二行展示训练深度学习来学习地球内黏弹性解的计算效率表示,使计算能够快速、可靠、高时空分辨率地完成(23)。第三行显示一个反演的例子,其中输入是非负的最小二乘法重建,对网络训练,将投影重构成一个子空间。该方法为数据稀疏的反演问题的求解提供了方法,同时也获得了良好的重构效果(79)。在这里,(下面)采样在训练数据中被编码,该训练数据可以通过生成一个低维的潜在(隐含)空间来进行补偿,从而得到重建。第四行显示了将随机森林方法应用于连续声波数据提取断层摩擦和约束断层破裂时间的结果。该方法识别了预先被认为是噪声的信号(28) [转载经过了 John Wiley 和 Sons(23)、(28)和勘探地球物理学家协会的许可(35)]

进行分类(20)。

机器学习还可用于建模,或创建捕获数据集中关系和结构的表示。这可以采取一种建模形式,表示出数据和目标变量之间复杂、未知或未被完全理解的关系。例如,震源参数与地震峰值加速度之间的关系(21, 22)。机器学习还可用于建立近似或替代模型,以加快大型计算,包括数值模拟(23, 24)和反演(25)。反演问题与观测数据、计

算模型和物理相关联,以便能够推断地球科学中的物理系统。机器学习,尤其是深度学习,可以帮助分析反演问题(26)。采用反演问题本身的深度神经网络体系可以学习传统重建临界速度的逆映射,对机器学习模型的泛化分析可以深入了解反演问题的不稳定性。

数据驱动的发现,即从数据中提取新信息的能力,是机器学习在科学应用中最令人




图4 机器学习方法及其应用(原图为彩色图——译注)。固体地球科学中的机器学习应用主要分为两类：无监督学习和监督学习。在监督学习任务，如预测(21, 28)和分类(16, 20)中，目标是基于已知(标注的)目标模式示例学习通用模型。在无监督学习任务中，目标是学习数据中的结构，例如稀疏或低维度特征表示(27)。其他类别的机器学习任务包括半监督学习(其中标注和未标注数据都可用于学习算法)和强化学习。深度神经网络代表了一类既包含监督学习任务又包括无监督学习任务的机器学习算法。深度学习算法已被用于学习特征表示(32, 89)，用于执行快速模拟的替代模型(23, 75)和联合概率分布(98, 100)

兴奋的能力之一。机器学习为科学家提供了一套工具，用于在科学数据集中发现通过传统技术难以揭示的新模式、新结构和新关系。机器学习可以发现先前未识别出的信号或者物理过程(27~31)，并提取表示、解释或可视化数据的关键特征(32~34)。例如，机器学习可以通过发现反直觉或出乎意料的模式有助于使误差最小化。它还可用于指导实验设计或者未来数据的收集(35)。

这些主题都是相互关联的，建模和反演还可以提供自动预测的能力，并且使用机器学习进行自动化、建模或反演可能会带来新的见解和基础发现。

2 监督学习的方法与趋势

监督学习方法使用收集的示例(训练数据)来学习关系和构建模型，这种模型对以

前未查看的数据是预测性的。监督学习是一组强大的工具，已成功地应用于涉及自动化、建模和反演以及发现等主题的应用程序中(图4)。在这一节中，我们建立了固体地球科学中最近的监督学习应用算法，该算法大致按照模型的复杂性排序，从相对简单的逻辑回归分类器开始，并以深度神经网络结束。通常，更复杂的模型需要更多的训练数据和更少的特征工程。

2.1 逻辑回归

逻辑回归(36)是一个简单的二进制分类器，它估计新数据点属于两个类其中一个的概率。Reynen 和 Audet(37)使用从地震波形数据中提取的偏振和频率特征，应用逻辑回归分类器自动区分了地震信号和爆破。他们通过将每个时间段分为地震或噪声类，将他们的方法扩展到检测连续数据中的地震。

他们使用每个地震台站的类概率来组合地震台网中多个台站的探测结果。Pawley 等(38)使用逻辑回归法将诱发地震活动的无震注水井与有震注水井分开,利用模型中的特征来识别地质因素,包括与诱发地震活动更高风险有关的井与基底的距离。

2.2 图解模型

地球科学中的许多数据集都有时间分量,例如地震仪记录的地面运动时间序列数据。虽然大多数机器学习算法都可适用于时间数据,但是一些方法(如图形模型)可以直接建模时态依赖关系。例如,隐马尔可夫模型就是一种用于时序数据建模的技术,并已被广泛应用于语音识别(39)。隐马尔可夫模型已应用于连续地震资料,用于对高山滑坡(40)、火山信号(41, 42)、区域地震(43)和诱发地震(44)的探测和分类。隐马尔可夫模型的详细解释及其在地震波形数据中的应用可详见 Hammer 等(42)。动态贝叶斯网络也被用于地震监测(45, 46),这是另一种推广隐马尔可夫模型的图形模型。在勘探地球物理学中,层次图形模型被应用于确定地下储层的连通性,这一过程是利用对流扩散方程导出的先验数据进行时间序列测量(47)。该文的作者指出,使用基于物理的先验是获得可靠模型的关键。基于图形的机器学习仿真程序曾由 Srinivasan 等(48)所使用,模拟通过裂缝网络流动的高性能物理计算,使裂缝系统的鲁棒不确定性量化成为可能(48)。

2.3 支持向量机

支持向量机是一种二进制分类算法,用于识别来自两类的训练数据之间的最优边界(49)。支持向量机使用核函数(泛化内积的相似函数)来实现数据到高维特征空间的隐式映射。带有线性核的支持向量机用超平面区分类,而非线性核函数考虑到了类之间的非线性决策边界[参考 Cracknell 和 Read

(50)以及 Shahnas 等(51)分别关于支持向量机和核方法的解释]。

Shahnas 等(51)运用支持向量机通过从温度场中求解反演估计地幔密度异常来研究地幔对流过程。利用地幔对流数值模拟计算得到的温度场作为训练数据。这些作者还运用支持向量机来预测地幔流动停滞的程度。在地震预警中,支持向量机(18)和支持向量回归(19)都已用于地震事件的震级快速估计。支持向量机也被用于区分地震和爆破(52),以及用于连续地震数据中的地震检测(53)。

2.4 随机森林和集成学习

决策树是一种有监督的分类和回归方法,它是分段常值函数,等价于一系列可以由二进制树形网络结构可视化的“如果—那么”规则。随机森林是一种集成学习算法,它可以通过在随机决策树集合(“森林”)中进行投票来学习复杂的关系(54)[关于随机森林的解释详见 Cracknell 和 Reading(50)]。随机森林相对而言是容易使用和解释的。与不透明或需要调优许多超参数的方法相比(例如,下文所述的神经网络),这些都是很大的优势,从而促进了随机森林在固体地球科学中的广泛应用。

Kuhn 等(35)绘制了西澳大利亚的岩性图,期间使用地球物理和遥感数据在一小部分地面上试验。Cracknell 和 Reading(55)发现,随机森林通过比较多个监督的机器学习算法,为地质填图提供了最佳的性能。随机森林预测还改进了三维(3D)地质模型,其使用了遥感地球物理数据来约束地球物理反转(56)。

Trugman 和 Shearer(21)从加利福尼亚北部的中强震级事件数据集中识别了应力降与峰值加速度的预测关系,这一过程采用的是随机森林来学习非线性、非参数地震动预测方程。这背离了典型的线性回归方法,即

用线性回归方法来模拟预期的峰值地动速度或加速度与定义地震动预测方程的地震场地和震源参数之间的关系。

Valera 等(24)用机器学习来描述地下裂隙形态(模拟流动和运移)的拓扑结构。离散裂隙网络的图示法允许随机森林和支持向量机识别描述整个网络的网络流动和运移的子网络。约化网络表示大大削减了估计系统行为所需的计算工作量。

Rouet-Leduc 等(28, 29)在实验室剪切实验中训练了连续声发射的随机森林, 以确定瞬时摩擦和预测破裂时间。根据使用相同实验室设备的连续声学数据, Hulbert 等(30)应用决策树方法确定实验室断层上的瞬时断层摩擦和位移。Rouet-Leduc 等(31)采用瞬时地震资料将该方法扩展应用到卡斯凯迪亚, 以全球定位系统数据为标记来预测俯冲板块界面的瞬时位移速率。在实验室和卡斯凯迪亚的实地研究中, 机器学习显示出了未知的信号。令人感兴趣的是, 同样的特征在实验室和现场都适用于推断断层物理性质, 表明了系统和比例的普遍性。

2.5 神经网络

人工神经网络是一种以脑内生物神经元相互连接的网络为松散模型的神经网络(57)。人工神经网络模型表示为由一组权重连接的节点(神经元)。每个节点接受来自上一层的值的加权线性组合, 并应用非线性函数来生成传递到下一层的单个值。“浅的”网络包含输入层(数据)、单隐层和输出层(预测响应)。Valentine 和 Woodhouse(58)对人工神经网络给出了详细解释, 以及根据训练数据学习权重的过程。人工神经网络可以用于回归和分类, 这取决于输出层的选择。

人工神经网络在地球科学中有悠久的历史 [早期工作的综述见(59, 60)], 它们仍然被广泛应用于建立一系列地球科学应

用中的非线性关系。De Wit 等(61)通过用人工神经网络求解贝叶斯逆问题, 依据 P 波走时数据估计了一维 P 波速度结构和模型不确定性。这种基于神经网络的方法可以替代使用标准的蒙特卡罗采样方法进行贝叶斯推理。Käufel 等(25)建立了一个人工神经网络模型, 根据强震数据估算震源参数。人工神经网络模型通过预计算复合密集模拟, 对源参数进行实时快速反演, 并用于训练神经网络模型。

人工神经网络已被用于估计短周期响应谱(62)、建立地面运动预测方程模型(22)、评估震源机制和震源位置的评估数据质量(58), 并执行噪声层析成像(63)。逻辑回归模型和人工神经网络模型使 Mousavi 等(64)可以描述地下塌陷和地面塌陷坑形成引起的微震震源深度。Kong 等(17)在基于智能手机的地震网络上使用少量易于计算的人工神经网络来区分地震动和由于用户活动而产生的运动。

3 深度神经网络

深度神经网络或者深度学习是经典人工神经网络的扩展, 结合了多个隐含层(65)。深度学习并不代表单一的算法, 而是具有多种网络结构的广泛的方法, 包括有监督的和无监督的方法。深度结构包括多个处理层和非线性变换, 每个层的输出作为输入传递到下一个层。有监督的深度神经网络同时从功能靶标中学习一个特征表示和标注, 在不需要查询好的选择特征输入的情况下, 可以获得良好的模型性能。Ross 等(66)提供一个关于卷积神经网络的说明性的例子, 是一类流行的深度神经网络, 具有特征提取的卷积层和用于分类和回归的完全连接层。然而, 深度网络的训练也需要大量的参数拟合, 这就需要大量的训练数据集和技术来防止模型的过度拟合(比如, 记住训练数据而不是学

习总趋势)。深度学习体系结构的复杂性也会使模型难以解释。

在模拟生成的数据上训练的神经网络可以学习一个近似物理模拟输出的模型。DeVries 等(23)使用深度、完全连接的神经网络获得了一个紧凑的模型,该模型可以精确地再现地球随时间变化的变形,其模式是计算密集的程序,用于求解无限黏弹性半空间上弹性层的地震响应。用于训练网络而生成模拟数据需要大量的计算开销,该模型一旦被训练成一个快速的算子,就可以加速新的黏弹性解的数量级计算。Moseley 等(67)使用神经网络对有限差分模型的合成数据进行训练,进行快速全波场模拟。

Shoji 等(20)用神经网络对火山灰颗粒的形状进行分类,四个类别分别对应于不同的物理喷发机制。这些作者使用网络返回的类概率来识别复杂形状的灰粒子,这项任务对于专家分析人员来说是困难的。

最近几项研究已经应用具有不同结构的神经网络,进行地震和地震事件检测(16, 68, 69)、震相拾取(66, 70)和火山地震事件的分类(71)。Wiszniowski 等(72)将递归神经网络应用于实时地震监测算法中,该结构设计用于顺序数据。Magaña-Zook 和 Ruppert(73)使用顺序数据的复杂递归神经网络结构的长短期记忆网络(74)来辨别天然地震活动和爆破。神经网络应用于地震监测的一个优点是,特征提取是由网络执行的,因此需要最少的预处理。通过比较,浅层深度神经网络和其他经典学习算法要求用户选择一组关键的鉴别特征,而较差的特征选择会影响模型的性能。由于很难确定地震波形的识别特征,深度神经网络的自动特征提取可以提高检测性能,但要有大量的训练集。

Arya-Polo 等(75)使用神经网络来学习基本类型的层析成像的反演。他们的目标是直接根据原始地震数据学习估算波速模

型,而不是使用机器学习来自动化或改进标准工作流的各个单元。神经网络模型比传统方法计算模型更快。

了解神经网络的基本性质和可解释性是一个非常有效的研究思路。散射变换(76, 77)可以在卷积神经网络中提供与地学相关的自然洞察力。这种变换是一个定义矩的放弃震相的复杂卷积神经网络,从而暴露出隐含在相位波动之下的频谱相关性。设计的散射变换具有理想的不变量。平稳过程的散射表示包括它们的二阶和高阶矩描述子。例如,散射变换可以有效地捕捉多重分形分析(78)和分层连续介质渗流中分别与沉积过程和多孔介质运移有关的关键性质。通过对地球科学中反演问题的分析,已得到了可解释的深度神经网络体系结构(79)。与原始重构和结合稀疏数据采集和促进作用的算法相比,这些都可能是大进展。

4 无监督学习的方法与趋势

4.1 聚类 and 自组织映射

有许多不同的聚类算法,包括 K 均值、层次聚类和自组织映射。自组织映射是一种无监督的神经网络,可用于降维或聚类(80)[自组织映射解释详见 Roden 等(81)]。Carneiro 等(33)将自组织映射应用于航空地球物理数据,以识别巴西亚马孙地区地质填图的关键地球物理特征,并确定它们与岩石类型的关系。Roden 等(81)利用主成分分析(或称主元分析 PCA)对地震属性进行特征识别,结合主成分分析进行维数缩减,然后进行聚类。自组织映射通常用于识别地震岩相,但是标准自组织映射不考虑数据点之间的空间关系。Zhao 等(82)建议对自组织映射算法施加地层学约束,以获得更详细的相图。自组织映射还被应用于地震波形数据中,用于特征选择(83)和聚类信号以识别多

个事件类型(84, 85)。

在机器学习工作流程中,通常将监督技术学习和无监督技术学习并行使用。Cracknell 等(86)根据地球物理和地球化学调查资料,训练随机森林分类器对岩性进行鉴别。然后,他们将自组织映射应用于随机森林生成的地质图的火山单元,以识别揭示合成差异的子单元。在地球科学中,通常有大型数据集,其中只有一小部分数据子集被标注。这种情况需要对半监督学习方法进行设计来学习标注和未标注的数据。在半监督学习方法中,Köhler 等(87)利用自组织映射来检测连续波形数据中的岩崩和火山构造事件,其中用基于少量已知示例来对每个聚类标签进行聚类 and 分配。Sick 等(88)也使用最近邻分类的自组织映射来分类地震事件的类型(采石场爆破和地震)和深度。

4.2 特征学习

无监督特征学习可用于学习数据集的低维或稀疏特征表示。Valentine 和 Trampert (32)使用自动编码器网络学习地震波形的紧凑型特征表示,这是一种为学习数据的高效编码而设计的无监督的深度神经网络。Qian 等(89)将深度卷积自编码器网络应用于叠前地震数据,学习可用于相图绘制聚类算法的特征表示。

Holtzman 等(27)将非负矩阵因子分解和隐马尔科夫模型结合起来,学习表征地震波形的特征。K 均值聚类应用于这些特征来识别间歇性温泉中 46 000 次低震级地震的临时模式。该文作者发现注水速率与地震频谱特性相关。

4.3 字典学习

稀疏字典学习是一种表征学习方法,它以基本元素或原子以及这些基本元素本身的线性组合的形式构造稀疏表示。原子字典是从一组输入数据中学习,同时找到稀疏表

征。字典学习方法学习数据稀疏表示的基础过于完备,已被用于消除噪声(90, 91)。Bianco 和 Gerstoft(92)研制了一种线性化(面波)走时层析成像方法,该方法从离散慢度图出发遵循最大后验公式完成像素重叠组的稀疏模拟局部行为。他们采用迭代阈值和有正负之分的 K 均值字典学习从走时扰动来增强估计慢度表示的稀疏度。

4.4 深度生成模型

生成模型是一类在数据集中学习联合概率分布的机器学习方法。生成模型既适用于无监督学习任务,也适用于监督学习任务。最近的工作探索了深度生成模型的应用,特别是生成对抗网络(93)。生成对抗网络是具有相对目标的两个神经网络的系统:一种是生成器网络,使用训练数据学习模型来生成真实合成数据;另一种是判别器网络,学习区分合成数据和真实训练数据[详细解释见(94)]。

深度生成模型,如深度绘制模型(95)、变分自编码器(96)、生成对抗网络(93),是分层概率模型,在多个抽象级别解释数据,从而加速学习。由于强烈的感应偏差和接触更多数据,这些模型中抽象的功率允许更高级别的学习概念和比它们级别更低的类别要更快速(97)。深度生成模型的无监督学习能够特别吸引地球物理学中的许多反演问题,因为在地球物理学中,通常没有标签。

与数值模拟模型相比,神经网络的使用本质上能够大大减少生成合成地震图所需的计算费用。Krischer 和 Fichtner(98)使用生成对抗网络将震源和接收参数映射为合成的多分量地震图。Mosser 等(99)采用类似于艺术风格转换的域转移方法,利用深度卷积生成对抗网络学习绘制从地震振幅到地质构造的映射,反之亦然。这些作者的方法使得模型正演和快速转换成为可能。生成对抗网络也被 Dupont 等(100)应用于地质建模中,

他们从有限数量的岩石类型来推断河流环境,使用类似于用于图像修复的生成对抗网络的局部地质模式。Chan 和 Elsheikh(101)用生成对抗网络生成真实、复杂的地质结构和地下水流模型。Veillard 等(102)使用生成对抗网络和变分自编码器(96)解释三维地震数据中的地质构造。

5 其他技术

强化学习是一种机器学习框架,其中算法通过反复尝试学习做出决策,以获得最大的报偿。Draels 等(103)提出一种基于加强学习的方法,用于对阈值的观测动态选择,阈值是基于相邻台站观测的单台站地震检波器。该方法是一种通用的参数自动调整方法,可用于根据地震台网的信息提高单台站检波器的灵敏度。

最近的几项地震学研究使用快速近邻搜索技术来确定地震事件的震源机制(104)、估计地面运动和震源参数(105)或者用于地震检测的大规模模板匹配(106)。这三项应用中的每一个都需要已知或预先计算的地震特征的数据库,并使用高效的搜索算法来减少计算运行时间。相反,Yoon 等(107)采用无监督模式挖掘方法进行地震检测,作者利用快速相似搜索算法对连续波形数据进行相似或重复搜索,该方法发现了先前未知震源的新事件。这种方法已经扩展到多个台站(108),并且可以处理长达 10 年的连续数据(109)。

网络分析技术——可以用由边缘连接的节点的图形结构来表示的分析数据的方法,也被用于在固体地球科学中进行数据驱动的发现。Riahi 和 Gerstoft(110)使用图聚类技术在密集的地震传感器阵列中检测弱震源。作者通过计算图的分量来识别震源,其中每个传感器是节点,并且边缘由阵列相干矩阵确定。Aguiar 和 Beroza(111)采用 Page-

Rank,即一种用于链路分析的流行算法,来分析波形与发现潜在低频地震信号之间的关系。

6 建议和机会

机器学习技术已被应用于固体地球科学中一系列广泛的问题,然而,它们的影响是有限的(图 5)。数据方面的挑战可能会阻碍新机器学习工具的进展和采用,但是,这些方法的采用滞后于其他一些具有类似数据质量问题的科学领域。

我们的建议是基于地球科学数据集的特性提出的,这些特征对标准机器学习算法提出了挑战。固体地球科学中的数据集代表了复杂的、非线性的、物理学的系统,其起作用的空间范围长度和时间尺度都很大。许多现象都是强度非平稳的,如流体注入和地震。所得到的数据是复杂的,具有需要创新方法的多分辨率、空间和时间结构。此外,许多现有的数据都没有标注。当数据可用时,标注常常是高度主观的或偏向于频繁的特征良好的现象,限制了依赖于训练数据集的算法的有效性。由于数据收集不均衡、数据集不完整和数据含噪声很常见,数据集的质量和完整性产生了另一个挑战。

6.1 基准数据集

在固体地球科学问题中缺乏明确真实而标准的基准,妨碍了对地球科学应用中的性能评价。评估性能的真实或参考数据,或许不可用、不完整,或有偏差。如果没有合适的真实数据,验证算法、评估性能和采用最佳实践就非常困难。地震自动检测就提供了一个说明性的例子。在过去几十年中,已经定期开发和应用了新的信号处理或基于机器学习的地震检测算法。每种方法都被应用于不同的数据集,并且作者们在没有真实依据的情况下设置了他们自己的评估性能标准。




图5 推进地球科学中机器学习的建议(原图为彩色图——译注)。在地球科学中取得机器学习应用的快速进展,从大学本科阶段开始的教育是关键。机器学习提供了一套重要的新工具,如果下一代在使用上受过良好的训练,它将迅速推进科学和工程发展。开源软件也是重要的组成部分,比如 Sci-kit Learn, TensorFlow 等,以及所有人都可以免费访问的开放获取出版物,比如 LANL/Cornell arXiv 和 PLOS(公共科学图书馆)。选择适当的机器学习方法和根据需要开发新的体系结构也同样重要。与机器学习的专家一同工作是目前最好的方法,直到地球科学领域有许多这方面的专家为止。竞赛、会议和专项会议也有助于推动这一领域的发展

这使得很难确定每种方法的相对检测性能、优点和弱点,从而导致学界未能采用和重复使用最好的新检测算法。

基准数据集和挑战问题在机器学习研究的推动进展和创新中发挥了重要作用。高质量的基准数据集具有两个关键优势:(i)增强严格的性能比较;(ii)生成更好的模型。众所周知的挑战问题包括精通游戏(112~115)、电影推荐的竞赛 [Netflix 奖(15)] 和图像识别 [ImageNet(14)]。美国有线电

视新闻网(CNN, 116)的表演示范在 2012 年的 ImageNet 竞赛引发了一波深度学习的研究浪潮。在计算机视觉中,在标准数据集上报告新算法的性能是常见的做法(117),如 MNIST 手写数字数据集。

如果更多更广泛地使用基准数据集,则可以在将机器学习应用于固体地球科学中的问题方面加速取得进展。这将需要研究界的投资,表现在创建和维护数据集方面,以及在发表的作品中报告算法在基准数据集上的

性能。编译和共享基准数据集的贡献不可被忽视。ImageNet 图像识别数据集(118)在 6 000 多篇论文中被引用。

最近,中国地震局地球物理研究所与阿里云计算有限公司主办了一次数据科学竞赛,1 000 多个团队围绕 2008 年 M_s 8.0 汶川地震(119, 120)余震的自动检测和震相拾取开展竞赛。真实相位到达数据,是评定参赛人员的依据,由中国地震局分析人员确定。对于那些试图测试和改进他们的检测算法的研究人员来说,这样的挑战是有用的。如果竞赛伴有某种形式的更广泛的后续行动,例如提供有关表现最佳参赛人员的出版物或给出有效方法的摘要和介绍竞赛组织者得到的经验教训,那么未来的竞赛应该有更大的影响。

当基础数据未被完全理解时,创建基准数据集和确定评价指标具有挑战性。将真实情况用作基准可能会有与训练数据同样的偏差。虽然基准数据集可以提供有用的指南,但是研究团体未必不重视或惩罚在真实情况中发现没有表现出来的新现象的方法。性能评估需要包括总误差率,以及相对的优势和弱点,也包括算法产生的各种误差(121)。在理想情况下,在给定的问题范围内,几个不同的基准数据集会提供给研究团体,以避免过于狭隘地关注于算法开发。例如,地震检测算法的性能可以根据要检测的事件类型和噪声信号特性而有所不同(比如,区域事件、火山地震、构造地震)。另一种方法是从模拟中创建数据集,其中模拟数据被发布,但基础模型被隐藏起来,比如,基于地震反射数据的复杂断层几何模型。这样,研究人员就可以通过竞争来确定什么方法最好恢复输入模型。

6.2 开放科学

开放科学原则的采纳(122)将更好地确定固体地球科学界的位置来提高人工智能的

快速发展速度。这应该包括制定代码的承诺(开源码)、数据集(开源数据)和研究(开源输入)均免费获得。对于验证和确保更难解释的“黑匣子”机器学习模型(如深度神经网络)的结果的重现性,开放科学尤为重要。

经常通过在线平台(123, 124)共享的开源代码,已经借助 ObsPy(125, 126)和 Pyrocko(127)工具箱被用于地震学中的常规数据处理。Scikit-learn 是另一个广泛应用于开源代码的例子(128)。随着基准数据集的增加,加强代码共享,即实施新的基于机器学习的解决方案,将有助于加快这些新方法的开发和验证。作为可用的开源代码,类似地震探测效益的积极研究领域能够对同一数据集上的多个算法进行直接比较,以评估相对性能。在可能的程度上,这也应扩展到原始数据集和预先训练的机器学习模型的共享。

使用电子预印本[比如(129~131)]也许有助于加快地球科学与人工智能交叉研究的前进步伐(132)。在正式审查程序之前,预印使作者可以与更广泛的团队接收反馈和分享初步结果。在预印服务器上提供研究的实践在许多科学、科技、工程和数学领域内是常见的,包括计算机视觉和自然局域网的处理,这两个领域都是推动深度学习发展的(133);但是,这一实践做法尚未在固体地球科学界中得到广泛采用。

6.3 新数据源

近年来新的、非传统的数据源已经开始使用,但是还没有被充分利用,这为基于机器学习的新型分析工具的应用与开发提供了新的机会。数据源,比如光雷达(LiDAR)点云(134)、基于光纤电缆的分布式声传感(135~137)、来自智能手机的大量人员数据(17)、社会化媒体(138, 139)、网页流量(140)和微机电系统加速计(141)等,都是非常适合使用机器学习的应用程序。干涉合成

孔径雷达(InSAR)数据广泛用于识别农作物或毁林等工作中,但在机器学习应用中,对地质和地球物理问题的应用却很少。高分辨率卫星和多光谱图像(142)提供丰富的地质和地球物理应用的数据集,包括火山、地震、地表变化、测绘地质和土壤等演化系统的研究。非政府卫星数据的缺点可能是成本。来自比如谷歌地图资料的图像数据或来自诸如 SPOT 和 ASTER 的政府赞助卫星的低分辨率多光谱数据是免费的。

6.4 机器学习解决方案、新模型和体系结构

研究人员有许多机会在地学和机器学习团队之间进行合作研究,包括新的模型和算法来解决固体地球科学中出现的数据难题[也见 Karpatne 等(143)]。地球物理传感器的实时数据收集提供了用于在流数据中在线学习的新的测试例子。需要领域专业知识来解释许多地球科学数据集,使这些有趣的事例用于开发交互式机器学习算法,包括环路系统。

完全由数据驱动的方法带来的挑战是需要大量的培训数据,特别是通过深度学习进行建模。此外,机器学习模型可能会终止复制训练数据中的偏差,这种偏差可能出现在数据收集期间,甚至通过使用特定的培训数据集而出现。因此,从地球科学数据集中提取最大值需要使用有限的、弱的或有偏差的标注能够学习的方法。此外,由于感兴趣的现象是由复杂的和动态物理过程控制的,因此有必要采用新的方法来分析将数据驱动和物理模型结合在一起的科学数据集(144)。

现代机器学习技术的许多表现力,例如深度神经网络,都来自于在既定的物理和数学框架之外识别数据反演路径的能力,这种能力通过非线性产生高度现实但非凸的正则化。最近,在分析地球科学(79)中反演问题的基础上,建立了可解释的深度神经网络体系结构,这些反演问题具有潜力来减少不适

定、加速重建(训练后)和适应稀疏(受限)数据采集。在线性逆问题的框架内,各种成像算子导致出特定的网络结构体系(26)。此外,深度生成模型将在逆问题的多级正则化迭代技术与深度学习的连接方面发挥重要作用。在相同情况下,先验可以从数据中学习。

另一种减轻深度学习依赖大型数据集的方法是用模拟生成补充的合成训练数据。在这种情况下,可以使用域适配来校正真实和合成数据之间数据分布的差异。域适配体系结构,包括混合现实生成对抗性网络(145),迭代地将模拟数据映射到真实数据的空间,反之亦然。研究经过训练的深度生成模型可以深入了解基础数据生成过程,而反演这些模型涉及推理算法,这些算法可以从数据中提取有用的表示形式。

应用机器学习方法处理地球科学问题的注意事项:机器学习不应简单地应用于复杂的地球科学问题。有偏差的数据、混合的培训和测试数据、过度拟合和不适当的验证将导致不可靠的结果。与其他地方一样,与数据科学家合作将有助于缓解这些潜在问题。

6.5 地球科学课程

数据科学正在迅速发展,地球科学家将得益于与机器学习研究人员(146)的密切合作,可充分利用最前沿的发展。协作需要地球科学家在工作中集中努力。地球科学课程中加大数据科学和机器学习的部分会有帮助,同样也可以招募受过数据科学培训的学生从事地球科学研究。跨学科的研究会议可以而且正在通过确定共同兴趣和互补能力来促进合作。

参考文献

1. P. Baldi, P. Sadowski, D. Whiteson, Searching for exotic particles in high-energy physics with deep learning. *Nat. Commun.* **5**, 4308 (2014). doi: 10.1038/ncomms5308; pmid:24986233

2. A. A. Melnikov, H. P. Nautrup, M. Krenn, V. Dunjko, M. Tiersch, A. Zeilinger, H. J. Briegel, Active learning machine learns to create new quantum experiments. *Proc. Natl. Acad. Sci. USA*, **115**, 1221 — 1226 (2018). doi: 10.1073/pnas.1714936115
3. C. J. Shallue, A. Vanderburg, Identifying Exoplanets with Deep Learning: A Five-planet Resonant Chain around Kepler-80 and an Eighth Planet around Kepler-90. *Astron. J.*, **155**, 94 (2018). doi: 10.3847/1538-3881/aa9e09
4. F. Ren, L. Ward, T. Williams, K. J. Laws, C. Wolverton, J. Hattrick-Simpers, A. Mehta, Accelerated discovery of metallic glasses through iteration of machine learning and high-throughput experiments. *Sci. Adv.*, **4**, eaaq1566 (2018).
5. M. I. Jordan, T. M. Mitchell, Machine learning: Trends, perspectives, and prospects. *Science*, **349**, 255 — 260 (2015). doi: 10.1126/science.aaa8415; pmid: 26185243
6. R. Kohavi, F. Provost, Glossary of terms. Machine Learning—Special Issue on Applications of Machine Learning and the Knowledge Discovery Process. *Mach. Learn.*, **30**, 271 — 274 (1998). doi: 10.1023/A:1017181826899
7. J. McCarthy, E. Feigenbaum, In Memoriam. Arthur Samuel: Pioneer in Machine Learning. *AI Mag.*, **11**, 10 (1990). doi.org/10.1609/aimag.v11i3.840
8. I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning* (MIT Press, 2016).
9. G. Litjens, T. Kooi, B. E. Bejnordi, A. A. A. Setio, F. Ciompi, M. Ghafoorian, J. A. van der Laak, B. van Ginneken, C. I. Sanchez, A survey on deep learning in medical image analysis. *Med. Image Anal.*, **42**, 60 — 88 (2017). doi: 10.1016/j.media.2017.07.005; pmid: 28778026
10. Q. V. Le, Building high-level features using large-scale unsupervised learning, in 2013 *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (IEEE, 2013), pp. 8595 — 8598.
11. F. U. Dowla, S. R. Taylor, R. W. Anderson, Seismic discrimination with artificial neural networks: Preliminary results with regional spectral data. *Bull. Seismol. Soc. Am.*, **80**, 1346 — 1373 (1990).
12. P. S. Dysart, J. J. Pulli, Regional seismic event classification at the NORESS array: Seismological measurements and the use of trained neural networks. *Bull. Seismol. Soc. Am.*, **80**, 1910 (1990).
13. H. Dai, C. MacBeth, Automatic picking of seismic arrivals in local earthquake data using an artificial neural network. *Geophys. J. Int.*, **120**, 758 — 774 (1995). doi: 10.1111/j.1365-246X.1995.tb01851.x
14. O. Russakovsky *et al.*, ImageNet Large Scale Visual Recognition Challenge. *Int. J. Comput. Vis.*, **115**, 211 — 252 (2015). doi: 10.1007/s11263-015-0816-y
15. J. Bennett, S. Lanning, The Netflix Prize, in *Proceedings of KDD cup and workshop* (New York, 2007), vol. 2007, p. 35.
16. T. Perol, M. Gharbi, M. Denolle, Convolutional neural network for earthquake detection and location. *Sci. Adv.*, **4**, e1700578 (2018). doi: 10.1126/sciadv.1700578; pmid: 29487899
17. Q. Kong, R. M. Allen, L. Schreier, Y.-W. Kwon, MyShake: A smartphone seismic network for earthquake early warning and beyond. *Sci. Adv.*, **2**, e1501055 (2016). doi: 10.1126/sciadv.1501055; pmid: 26933682
18. R. Reddy, R. R. Nair, The efficacy of support vector machines (SVM) in robust determination of earthquake early warning magnitudes in central Japan. *J. Earth Syst. Sci.*, **122**, 1423 — 1434 (2013). doi: 10.1007/s12040-013-0346-3
19. L. H. Ochoa, L. F. Niño, C. A. Vargas, Fast magnitude determination using a single seismological station record implementing machine learning techniques. *Geodesy Geodyn.*, **9**, 34 — 41 (2017). doi: 10.1016/j.geog.2017.03.010
20. D. Shoji, R. Noguchi, S. Otsuki, H. Hino, Classification of volcanic ash particles using a convolutional neural network and probability. *Sci. Rep.*, **8**, 8111 (2018). doi: 10.1038/s41598-018-26200-2; pmid: 29802305
21. D. T. Trugman, P. M. Shearer, Strong Correlation between Stress Drop and Peak Ground Acceleration for Recent M1-4 Earthquakes in the San Francisco Bay Area. *Bull. Seismol. Soc. Am.*, **108**, 929 — 945 (2018). doi: 10.1785/0120170245
22. B. Derras, P. Y. Bard, F. Cotton, Towards fully data driven ground-motion prediction models for Europe. *Bull. Earthquake Eng.*, **12**, 495 — 516 (2014). doi: 10.1007/s10518-013-9481-0
23. P. M. R. De Vries, T. B. Thompson, B. J. Meade, Enabling large-scale viscoelastic calculations via neural network acceleration. *Geophys. Res. Lett.*, **44**, 2662 — 2669 (2017). doi: 10.1002/2017GL072716
24. M. Valera, Z. Guo, P. Kelly, S. Matz, V. A. Cantu, A. G. Percus, J. D. Hyman, G. Srinivasan, H. S. Viswanathan, Machine learning for graph-based representations of three-dimensional discrete fracture networks. *Computat. Geosci.*, **22**, 695 — 710 (2018). doi: 10.1007/s10596-018-9720-1
25. P. Käufel, A. P. Valentine, J. Trampert, Probabilistic point source inversion of strong-motion data in 3-D media using pattern recognition: A case study for the 2008 M_w5.4 Chino Hills earthquake. *Geophys. Res. Lett.*, **43**, 8492 — 8498 (2016). doi: 10.1002/2016GL069887
26. M. T. McCann, K. H. Jin, M. Unser, Convolutional Neural

- Networks for Inverse Problems in Imaging; A Review. *IEEE Signal Process. Mag.* **34**, 85–95 (2017). doi: 10.1109/MSP.2017.2739299
27. B. K. Holtzman, A. Paté, J. Paisley, F. Waldhauser, D. Repetto, Machine learning reveals cyclic changes in seismic source spectra in Geysers geothermal field. *Sci. Adv.* **4**, eaao2929 (2018). doi: 10.1126/sciadv. aao2929; pmid:29806015
28. B. Rouet-Leduc, C. Hulbert, N. Lubbers, K. Barros, C. J. Humphreys, P. A. Johnson, Machine Learning Predicts Laboratory Earthquakes. *Geophys. Res. Lett.* **44**, 9276–9282 (2017). doi: 10.1002/2017GL 074677
29. B. Rouet-Leduc, C. Hulbert, D. C. Bolton, C. X. Ren, J. Riviere, C. Marone, R. A. Guyer, P. A. Johnson, Estimating Fault Friction From Seismic Signals in the Laboratory. *Geophys. Res. Lett.* **45**, 1321–1329 (2018). doi: 10.1002/2017GL076708
30. C. Hulbert, B. Rouet-Leduc, P. Johnson, C. X. Ren, J. Riviere, D. C. Bolton, C. Marone, Similarity of fast and slow earthquakes illuminated by machine learning. *Nat. Geosci.* **12**, 69–74 (2019). doi: 10.1038/s41561-018-0272-8
31. B. Rouet-Leduc, C. Hulbert, P. A. Johnson, Continuous chatter of the Cascadia subduction zone revealed by machine learning. *Nat. Geosci.* **12**, 75–79 (2019). doi: 10.1038/s41561-018-0274-6
32. A. P. Valentine, J. Trampert, Data space reduction, quality assessment and searching of seismograms; Autoencoder networks for waveform data. *Geophys. J. Int.* **189**, 1183–1202 (2012). doi: 10.1111/j.1365-246X.2012.05429.x
33. C. C. Carneiro, S. J. Fraser, A. P. Crósta, A. M. Silva, C. E. M. Barros, Semiautomated geologic mapping using self-organizing maps and airborne geophysics in the Brazilian Amazon. *Geophysics* **77**, K17–K24 (2012). doi: 10.1190/geo2011-0302.1
34. X. Wu, D. Hale, 3D seismic image processing for faults. *Geophysics* **81**, IM1–IM11 (2016). doi: 10.1190/geo2015-0380.1
35. S. Kuhn, M. J. Cracknell, A. M. Reading, Lithologic mapping using Random Forests applied to geophysical and remotesensing data: A demonstration study from the Eastern Goldfields of Australia. *Geophysics* **83**, B183–B193 (2018). doi: 10.1190/geo2017-0590.1
36. D. R. Cox, The Regression Analysis of Binary Sequences. *J. R. Stat. Soc. B* **20**, 215–232 (1958). doi: 10.1111/j.2517-6161.1958.tb00292.x
37. A. Reynen, P. Audet, Supervised machine learning on a network scale; Application to seismic event classification and detection. *Geophys. J. Int.* **210**, 1394–1409 (2017). doi: 10.1093/gji/ggx238
38. S. Pawley, R. Schultz, T. Playter, H. Corlett, T. Shipman, S. Lyster, T. Hauck, The Geological Susceptibility of Induced Earthquakes in the Duvernay Play. *Geophys. Res. Lett.* **45**, 1786–1793 (2018). doi: 10.1002/2017GL076100
39. L. R. Rabiner, A tutorial on hidden Markov models and selected applications in speech recognition. *Proc. IEEE* **77**, 257–286 (1989). doi: 10.1109/5.18626
40. F. Dammeier, J. R. Moore, C. Hammer, F. Haslinger, S. Loew, Automatic detection of alpine rockslides in continuous seismic data using hidden Markov models. *J. Geophys. Res. Earth Surf.* **121**, 351–371 (2016). doi: 10.1002/2015JF003647
41. M. Beyreuther, R. Carniel, J. Wassermann, Continuous Hidden Markov Models; Application to automatic earthquake detection and classification at Las Canadas caldera, Tenerife. *J. Volcanol. Geotherm. Res.* **176**, 513–518 (2008). doi: 10.1016/j.jvolgeores.2008.04.021
42. C. Hammer, M. Beyreuther, M. Ohrnberger, A Seismic-Event Spotting System for Volcano Fast-Response Systems. *Bull. Seismol. Soc. Am.* **102**, 948–960 (2012). doi: 10.1785/0120110167
43. M. Beyreuther, J. Wassermann, Continuous earthquake detection and classification using discrete Hidden Markov Models. *Geophys. J. Int.* **175**, 1055–1066 (2008). doi: 10.1111/j.1365-246X.2008.03921.x
44. M. Beyreuther, C. Hammer, J. Wassermann, M. Ohrnberger, T. Megies, Constructing a Hidden Markov Model based earthquake detector; Application to induced seismicity. *Geophys. J. Int.* **189**, 602–610 (2012). doi: 10.1111/j.1365-246X.2012.05361.x
45. C. Riggelsen, M. Ohrnberger, F. Scherbaum, Dynamic Bayesian networks for real-time classification of seismic signals, in Knowledge Discovery in Databases. PKDD 2007. Lecture Notes in Computer Science, vol. 4702, J. N. Kok et al., Eds. (Springer, 2007), pp. 565–572. doi: 10.1007/978-3-540-74976-9_59
46. C. Riggelsen, M. Ohrnberger, A Machine Learning Approach for Improving the Detection Capabilities at 3C Seismic Stations. *Pure Appl. Geophys.* **171**, 395–411 (2014). doi: 10.1007/s00024-012-0592-3
47. F. Janoos, H. Denli, N. Subrahmanya, Multi-scale graphical models for spatio-temporal processes. *Adv. Neural Inf. Process. Syst.* **27**, 316–324 (2014).
48. S. Srinivasan, J. Hyman, S. Karra, D. O'Malley, H. Viswanathan, G. Srinivasan, Robust system size reduction of discrete fracture networks; A multi-fidelity method that preserves transport characteristics. *Computat. Geosci.* **22**, 1515–1526 (2018). doi: 10.1007/s10596-018-9770-4
49. C. Cortes, V. Vapnik, Support-vector networks. *Mach.*

- Learn.* **20**, 273–297 (1995). doi: 10.1023/A:1022627411411
50. M. J. Cracknell, A. M. Reading, The upside of uncertainty: Identification of lithology contact zones from airborne geophysics and satellite data using random forests and support vector machines. *Geophysics* **78**, WB113 – WB126 (2013). doi: 10.1190/geo2012-0411.1
 51. M. H. Shahnas, D. A. Yuen, R. N. Pysklywec, Inverse Problems in Geodynamics Using Machine Learning Algorithms. *J. Geophys. Res. Solid Earth* **123**, 296 – 310 (2018). doi: 10.1002/2017JB 014846
 52. J. Kortström, M. Uski, T. Tiira, Automatic classification of seismic events within a regional seismograph network. *Comput. Geosci.* **87**, 22 – 30 (2016). doi: 10.1016/j.cageo.2015.11.006
 53. A. E. Ruano, G. Madureira, O. Barros, H. R. Khosravani, M. G. Ruano, P. M. Ferreira, Seismic detection using support vector machines. *Neurocomputing* **135**, 273 – 283 (2014). doi: 10.1016/j.neucom.2013.12.020
 54. L. Breiman, Random Forests. *Mach. Learn.* **45**, 5 – 32 (2001). doi: 10.1023/A:1010933404324
 55. M. J. Cracknell, A. M. Reading, Geological mapping using remote sensing data: A comparison of five machine learning algorithms, their response to variations in the spatial distribution of training data and the use of explicit spatial information. *Comput. Geosci.* **63**, 22 – 33 (2014). doi: 10.1016/j.cageo.2013.10.008
 56. A. M. Reading, M. J. Cracknell, D. J. Bombardieri, T. Chalke, Combining Machine Learning and Geophysical Inversion for Applied Geophysics. ASEG Extended Abstracts 2015, 1 (2015). doi: 10.1071/ASEG2015ab070
 57. C. M. Bishop, *Neural Networks for Pattern Recognition* (Oxford Univ. Press, 1995).
 58. A. P. Valentine, J. H. Woodhouse, Approaches to automated data selection for global seismic tomography. *Geophys. J. Int.* **182**, 1001 – 1012 (2010). doi: 10.1111/j.1365-246X.2010.04658.x
 59. M. van der Baan, C. Jutten, Neural networks in geophysical applications. *Geophysics* **65**, 1032 – 1047 (2000). doi: 10.1190/1.1444797
 60. M. M. Poulton, Neural networks as an intelligence amplification tool: A review of applications. *Geophysics* **67**, 979–993 (2002). doi: 10.1190/1.1484539
 61. R. W. L. de Wit, A. P. Valentine, J. Trampert, Bayesian inference of Earth's radial seismic structure from body-wave traveltimes using neural networks. *Geophys. J. Int.* **195**, 408–422 (2013). doi: 10.1093/gji/ggt220
 62. R. Paolucci, F. Gatti, M. Infantino, C. Smerzini, A. Guney Ozcebe, M. Stupazzini, Broadband ground motions from 3D physics-based numerical simulations using artificial neural networks. *Bull. Seismol. Soc. Am.* **108**, 1272 – 1286 (2018).
 63. P. Paitz, A. Gokhberg, A. Fichtner, A neural network for noise correlation classification. *Geophys. J. Int.* **212**, 1468 – 1474 (2018). doi: 10.1093/gji/ggx495
 64. S. M. Mousavi, S. P. Horton, C. A. Langston, B. Samei, Seismic features and automatic discrimination of deep and shallow induced-microearthquakes using neural network and logistic regression. *Geophys. J. Int.* **207**, 29–46 (2016). doi: 10.1093/gji/ggw258
 65. Y. LeCun, Y. Bengio, G. Hinton, Deep learning. *Nature* **521**, 436 – 444 (2015). doi: 10.1038/nature14539; pmid:26017442
 66. Z. E. Ross, M.-A. Meier, E. Hauksson, P Wave Arrival Picking and First-Motion Polarity Determination With Deep Learning. *J. Geophys. Res. Solid Earth* **123**, 5120–5129 (2018). doi: 10.1029/2017JB015251
 67. B. Moseley, A. Markham, T. Nissen-Meyer, Fast approximate simulation of seismic waves with deep learning. arXiv:1807.06873[physics.geo-ph] (2018).
 68. Y. Wu, Y. Lin, Z. Zhou, D. C. Bolton, J. Liu, P. Johnson, Cascaded region-based densely connected network for event detection; A seismic application. arXiv:1709.07943 [cs.LG] (2017).
 69. Y. Wu, Y. Lin, Z. Zhou, A. Delorey, Seismic-Net: A deep densely connected neural network to detect seismic events. arXiv:1802.02241(eess.SP) (2018).
 70. W. Zhu, G. C. Beroza, PhaseNet: A deep-neural-network-based seismic arrival time picking method. arXiv:1803.03211[physics.geo-ph] (2018).
 71. M. Titos, A. Bueno, L. García, C. Benítez, A deep neural networks approach to automatic recognition systems for volcano-seismic events. *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.* **11**, 1533 – 1544 (2018). doi: 10.1109/JSTARS.2018.2803198
 72. J. Wiszniowski, B. Plesiewicz, J. Trojanowski, Application of real time recurrent neural network for detection of small natural earthquakes in Poland. *Acta Geophysica* **62**, 469–485 (2014). doi: 10.2478/s11600-013-0140-2
 73. S. A. Magaña-Zook, S. D. Ruppert, Explosion monitoring with machine learning: A LSTM approach to seismic event discrimination. American Geophysical Union Fall Meeting, abstract S43A-0834 (2017).
 74. S. Hochreiter, J. Schmidhuber, Long short-term memory. *Neural Comput.* **9**, 1735 – 1780 (1997). doi: 10.1162/neco.1997.9.8.1735; pmid:9377276
 75. M. Araya-Polo, J. Jennings, A. Adler, T. Dahlke, Deep-learning tomography. *Leading Edge (Tulsa Okla.)* **37**, 58–66 (2018). doi: 10.1190/tle 37010058.1
 76. S. Mallat, Group Invariant Scattering. *Commun. Pure Appl. Math.* **65**, 1331 – 1398 (2012). doi: 10.1002/

- cpa.21413
77. J. Bruna, S. Mallat, Invariant scattering convolution networks, *IEEE Trans. Pattern Anal. Mach. Intell.* **35**, 1872 — 1886 (2013). doi: 10.1109/TPAMI.2012.230; pmid:23787341
 78. J. Bruna, Scattering representations for recognition, Ph. D. thesis, Ecole Polytechnique X(2013).
 79. S. Gupta, K. Kothari, M. V. de Hoop, I. Dokmanic, Random mesh projectors for inverse problems, arXiv: 1805.11718[cs.CV](2018).
 80. T. Kohonen, Essentials of the self-organizing map, *Neural Netw.* **37**, 52 — 65 (2013). doi: 10.1016/j.neunet.2012.09.018; pmid:23067803
 81. R. Roden, T. Smith, D. Sacrey, Geologic pattern recognition from seismic attributes: Principal component analysis and self-organizing maps, *Interpretation (Tulsa)* **3**, SAE59 — SAE83 (2015). doi: 10.1190/INT-2015-0037.1
 82. T. Zhao, F. Li, K. J. Marfurt, Constraining self-organizing map facies analysis with stratigraphy: An approach to increase the credibility in automatic seismic facies classification, *Interpretation (Tulsa)* **5**, T163 — T171 (2017). doi: 10.1190/INT-2016-0132.1
 83. A. Köhler, M. Ohrnberger, C. Riggelsen, F. Scherbaum, Unsupervised feature selection for pattern search in seismic time series, Journal of Machine Learning Research, in *Workshop and Conference Proceedings: New challenges for Feature Selection in Data Mining and Knowledge Discovery*, vol. 4, pp. 106 — 121.
 84. A. Esposito, F. Giudicepietro, S. Scarpetta, L. D'Auria, M. Marinaro, M. Martini, Automatic Discrimination among Landslide, Explosion-Quake, and Microtremor Seismic Signals at Stromboli Volcano Using Neural Networks, *Bull. Seismol. Soc. Am.* **96**(4A), 1230 — 1240 (2006). doi: 10.1785/0120050097
 85. A. Esposito, F. Giudicepietro, L. D'Auria, S. Scarpetta, M. Martini, M. Coltelli, M. Marinaro, Unsupervised Neural Analysis of Very-Long-Period Events at Stromboli Volcano Using the Self-Organizing Maps, *Bull. Seismol. Soc. Am.* **98**, 2449 — 2459 (2008). doi: 10.1785/0120070110
 86. M. J. Cracknell, A. M. Reading, A. W. McNeill, Mapping geology and volcanic-hosted massive sulfide alteration in the Hellyer-Mt Charter region, Tasmania, using Random ForestsTM and Self-Organising Maps, *Aust. J. Earth Sci.* **61**, 287 — 304 (2014). doi: 10.1080/08120099.2014.858081
 87. A. Köhler, M. Ohrnberger, F. Scherbaum, Unsupervised pattern recognition in continuous seismic wavefield records using Self-Organizing Maps, *Geophys. J. Int.* **182**, 1619 — 1630 (2010). doi: 10.1111/j.1365-246X.2010.04709.x
 88. B. Sick, M. Guggenmos, M. Joswig, Chances and limits of single-station seismic event clustering by unsupervised pattern recognition, *Geophys. J. Int.* **201**, 1801 — 1813 (2015). doi: 10.1093/gji/ggv126
 89. F. Qian *et al.*, Unsupervised seismic facies analysis via deep convolutional autoencoders, *Geophysics* **83**, A39 — A43 (2018). doi: 10.1190/geo2017-0524.1
 90. S. Beckouche, J. Ma, Simultaneous dictionary learning and denoising for seismic data, *Geophysics* **79**, A27 — A31 (2014). doi: 10.1190/geo2013-0382.1
 91. Y. Chen, J. Ma, S. Fomel, Double-sparsity dictionary for seismic noise attenuation, *Geophysics* **81**, V103 — V116 (2016). doi: 10.1190/geo2014-0525.1
 92. M. Bianco, P. Gerstoft, Travel time tomography with adaptive dictionaries, arXiv: 1712.08655[physics.geo-ph] (2017).
 93. I. Goodfellow *et al.*, Generative adversarial networks, *Adv. Neural Inf. Process. Syst.* **27**, 2672 — 2680 (2014).
 94. L. Mosser, O. Dubrule, M. J. Blunt, Reconstruction of three-dimensional porous media using generative adversarial neural networks, *Phys. Rev. E* **96**, 043309 (2017). doi: 10.1103/PhysRevE.96.043309; pmid:29347591
 95. A. B. Patel, M. T. Nguyen, R. Baraniuk, A probabilistic framework for deep learning, *Adv. Neural Inf. Process. Syst.* **29**, 2558 — 2566 (2016).
 96. D. P. Kingma, M. Welling, Auto-encoding variational Bayes, arXiv: 1312.6114[stat.ML](2013).
 97. J. B. Tenenbaum, C. Kemp, T. L. Griffiths, N. D. Goodman, How to grow a mind: Statistics, structure, and abstraction, *Science* **331**, 1279 — 1285 (2011). doi: 10.1126/science.1192788; pmid:21393536
 98. L. Krischer, A. Fichtner, Generating seismograms with deep neural networks, AGU Fall Meeting Abstracts, abstract S41D-03 (2017).
 99. L. Mosser, W. Kimman, J. Dramsch, S. Purves, A. De la Fuente, G. Ganssle, Rapid seismic domain transfer: Seismic velocity inversion and modeling using deep generative neural networks, arXiv: 1805.08826[physics.geo-ph] (2018).
 100. E. Dupont, T. Zhang, P. Tilke, L. Liang, W. Bailey, Generating realistic geology conditioned on physical measurements with generative adversarial networks, arXiv: 1802.03065[stat.ML](2018).
 101. S. Chan, A. H. Elsheikh, Parametrization and generation of geological models with generative adversarial networks, arXiv: 1708.01810[stat.ML](2017).
 102. A. Veillard, O. Morère, M. Grout, J. Gruffeille, Fast 3D seismic interpretation with unsupervised deep learning: Application to a potash network in the North Sea, 80th EAGE Conference and Exhibition 2018 (2018). doi: 10.

- 3997/2214-4609.201800738
103. T. J. Draelos, M. G. Peterson, H. A. Knox, B. J. Lawry, K. E. Phillips-Alonge, A. E. Ziegler, E. P. Chael, C. J. Young, A. Faust, Dynamic tuning of seismic signal detector trigger levels for local networks *Bull. Seismol. Soc. Am.* **108**, 1346—1354 (2018). doi: 10.1785/0120170200
 104. J. Zhang, H. Zhang, E. Chen, Y. Zheng, W. Kuang, X. Zhang, Real-time earthquake monitoring using a search engine method. *Nat. Commun.* **5**, 5664 (2014). doi: 10.1038/ncomms6664; pmid: 25472861
 105. L. Yin, J. Andrews, T. Heaton, Reducing process delays for real-time earthquake parameter estimation—An application of KD tree to large databases for Earthquake Early Warning. *Comput. Geosci.* **114**, 22—29 (2018). doi: 10.1016/j.cageo.2018.01.001
 106. R. Tibi, C. Young, A. Gonzales, S. Ballard, A. Encarnacao, Rapid and robust cross-correlation-based seismic phase identification using an approximate nearest neighbor method. *Bull. Seismol. Soc. Am.* **107**, 1954—1968 (2017). doi: 10.1785/0120170011
 107. C. E. Yoon, O. O'Reilly, K. J. Bergen, G. C. Beroza, Earthquake detection through computationally efficient similarity search. *Sci. Adv.* **1**, e1501057 (2015). doi: 10.1126/sciadv.1501057; pmid: 26665176
 108. K. J. Bergen, G. C. Beroza, Detecting earthquakes over a seismic network using single-station similarity measures. *Geophys. J. Int.* **213**, 1984—1998 (2018). doi: 10.1093/gji/ggy100
 109. K. Rong, C. E. Yoon, K. J. Bergen, H. Elezabi, P. Bailis, P. Levis, G. C. Beroza, Locality-sensitive hashing for earthquake detection; A case study scaling data-driven science. *Proceedings of the International Conference on Very Large Data Bases (PVLDB)* **11**, 1674 (2018). doi: 10.14778/3236187.3236214
 110. N. Riahi, P. Gerstoft, Using graph clustering to locate sources within a dense sensor array. *Signal Processing* **132**, 110—120 (2017). doi: 10.1016/j.sigpro.2016.10.001
 111. A. C. Aguiar, G. C. Beroza, PageRank for Earthquakes. *Seismol. Res. Lett.* **85**, 344—350 (2014). doi: 10.1785/0220130162
 112. M. Campbell, A. J. Hoane Jr., F.-H. Hsu, Deep Blue. *Artif. Intell.* **134**, 57—83 (2002). doi: 10.1016/S0004-3702(01)00129-1
 113. D. Ferrucci, A. Levas, S. Bagchi, D. Gondek, E. T. Mueller, Watson: Beyond Jeopardy! *Artif. Intell.* **199**—**200**, 93—105 (2013). doi: 10.1016/j.artint.2012.06.009
 114. D. Silver *et al.*, Mastering the game of Go with deep neural networks and tree search. *Nature* **529**, 484—489 (2016). doi: 10.1038/nature 16961; pmid: 26819042
 115. M. Moravčík *et al.*, DeepStack: Expert-level artificial intelligence in heads-up no-limit poker. *Science* **356**, 508—513 (2017). doi: 10.1126/science. aam6960; pmid: 28254783
 116. A. Krizhevsky, I. Sutskever, G. E. Hinton, ImageNet classification with deep convolutional neural networks. *Adv. Neural Inf. Process. Syst.* **25**, 1097—1105 (2012).
 117. Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, Gradient-based learning applied to document recognition. *Proc. IEEE* **86**, 2278—2324 (1998). doi: 10.1109/5.726791
 118. J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, L. Fei-Fei, Imagenet: A large-scale hierarchical image database, in *Computer Vision and Pattern Recognition*, 2009. *CVPR 2009. IEEE Conference on (IEEE, 2009)*, pp. 248—255. doi: 10.1109/CVPR.2009.5206848
 119. Aftershock detection contest, <https://tianchi.aliyun.com/competition/introduction.htm?raceId=231606>; accessed: 7 September 2018.
 120. L. Fang, Z. Wu, K. Song, SeismOlympics. *Seismol. Res. Lett.* **88**, 1429—1430 (2017). doi: 10.1785/0220170134
 121. D. Sculley, J. Snoek, A. Wiltschko, A. Rahimi, Winner's curse? on pace, progress, and empirical rigor, in *International Conference on Learning Representations (ICLR) 2018 Workshop*. (2018); <https://openreview.net/forum?id=rJWF0Fyw>.
 122. Y. Gil *et al.*, Toward the Geoscience Paper of the Future: Best practices for documenting and sharing research from data to software to provenance. *Earth Space Sci.* **3**, 388—415 (2016). doi: 10.1002/2015EA000136
 123. GitHub, <https://github.com>.
 124. GitLab, <https://about.gitlab.com>.
 125. M. Beyreuther *et al.*, ObsPy: A Python Toolbox for Seismology. *Seismol. Res. Lett.* **81**, 530—533 (2010). doi: 10.1785/gssrl.81.3.530
 126. L. Krischer *et al.*, ObsPy: A bridge for seismology into the scientific Python ecosystem. *Comput. Sci. Discov.* **8**, 014003 (2015). doi: 10.1088/1749-4699/8/1/014003
 127. S. Heimann, *et al.*, Pyrocko—An open-source seismology toolbox and library. V. 0.3. GFZ Data Services. (2017). doi: 10.5880/GFZ.2.1.2017.001
 128. F. Pedregosa *et al.*, Scikit-learn: Machine Learning in Python. *J. Mach. Learn. Res.* **12**, 2825—2830 (2011).
 129. arXiv e-Print archive, <https://arxiv.org>.
 130. EarthArXiv Preprints, <https://eartharxiv.org>.
 131. Earth and Space Science Open Archive, <https://essoar.org>.
 132. J. Kaiser, The preprint dilemma. *Science* **357**, 1344—1349 (2017). doi: 10.1126/science. 357. 6358. 1344; pmid: 28963238
 133. C. Sutton, L. Gong, Popularity of arXiv.org within com-

- puter science, arXiv:1710.05225[cs.DL](2017).
134. A. J. Riquelme, A. Abellán, R. Tomás, M. Jaboyedoff, A new approach for semi-automatic rock mass joints recognition from 3D point clouds. *Comput. Geosci.* **68**, 38 — 52 (2014). doi:10.1016/j.cageo.2014.03.014
 135. N. J. Lindsey *et al.*, Fiber-Optic Network Observations of Earthquake Wavefields. *Geophys. Res. Lett.* **44**, 11, 792 — 11, 799 (2017). doi:10.1002/2017GL075722
 136. E. R. Martin *et al.*, A Seismic Shift in Scalable Acquisition Demands New Processing: Fiber-Optic Seismic Signal Retrieval in Urban Areas with Unsupervised Learning for Coherent Noise Removal. *IEEE Signal Process. Mag.* **35**, 31 — 40 (2018). doi: 10.1109/MSP.2017.2783381
 137. G. Marra *et al.*, Ultrastable laser interferometry for earthquake detection with terrestrial and submarine cables. *Science* **361**, 486 — 490 (2018). doi: 10.1126/science.aat4458
 138. T. Sakaki, M. Okazaki, Y. Matsuo, Earthquake shakes Twitter users: Real-time event detection by social sensors, in *Proceedings of the 19th International Conference on World Wide Web* (ACM, 2010), pp. 851 — 860. doi:10.1145/1772690.1772777
 139. P. S. Earle, D. C. Bowden, M. Guy, Twitter earthquake detection: Earthquake monitoring in a social world. *Ann. Geophys.* **54**, 708 — 715 (2012). doi: 10.4401/ag-5364
 140. R. Bossu, G. Mazet-Roux, V. Douet, S. Rives, S. Marin, M. Aupetit, Internet Users as Seismic Sensors for Improved Earthquake Response. *Eos* **89**, 225 — 226 (2008). doi:10.1029/2008EO 250001
 141. E. S. Cochran, J. F. Lawrence, C. Christensen, R. S. Jukka, The Quake-Catcher Network: Citizen Science Expanding Seismic Horizons. *Seismol. Res. Lett.* **80**, 26 — 30 (2009). doi:10.1785/gssrl.80.1.26
 142. DigitalGlobe, <http://www.digitalglobe.com>.
 143. A. Karpatne, I. Ebert-Uphoff, S. Ravela, H. A. Babaie, V. Kumar, Machine learning for the geosciences: Challenges and opportunities. arXiv: 1711. 04708 [cs. LG] (2017).
 144. A. Karpatne *et al.*, Theory-Guided Data Science: A New Paradigm for Scientific Discovery from Data. *IEEE Trans. Knowl. Data Eng.* **29**, 2318 — 2331 (2017). doi: 10.1109/TKDE.2017.2720168
 145. J.-Y. Zhu, T. Park, P. Isola, A. A. Efros, Unpaired image-to-image translation using cycle-consistent adversarial networks. arXiv:1703.10593[cs.CV](2017).
 146. I. Ebert-Uphoff, Y. Deng, Three steps to successful collaboration with data scientists. *Eos* **98**, (2017). doi:10.1029/2017EO079977

译者简介



张美玲(1987—), 女, 中国地震局工程力学研究所防灾减灾工程及防护工程专业硕士研究生毕业。目前在黑龙江省地震局工作, 主要从事地震监测、地震应急、地震烈度速报与预警等相关工作。E-mail: zml_iem@163.com。